

Caracterización de perfiles de pacientes diabéticos hospitalizados a partir de variables demográficas, clínicas y de uso hospitalario

Rodríguez Chacón, María D.

Ingeniería de Sistemas

Facultad de Ingeniería

Universidad de Antioquia

Medellín, Antioquia

mdaniela.rodriguez@udea.edu.co

Agudelo Ochoa, David.

Ingeniería de Sistemas

Facultad de Ingeniería

Universidad de Antioquia

Medellín, Antioquia

david.agudeloo@udea.edu.co

Resumen— Este estudio analiza el conjunto de datos Diabetes 130-US Hospitals, el cual contiene 101.766 registros de pacientes diabéticos atendidos en 130 hospitales de Estados Unidos durante el período 1999–2008. El objetivo es identificar perfiles diferenciados de pacientes a partir de variables demográficas, clínicas y de utilización de servicios de salud mediante un enfoque exploratorio no supervisado. La metodología incluyó análisis univariados y bivariados, detección de valores atípicos mediante los métodos IQR, Z-score e Isolation Forest, imputación y codificación de variables categóricas, escalamiento con StandardScaler, reducción de dimensionalidad mediante PCA (9 componentes que explican más del 80 % de la varianza) y agrupamiento con K-Means ($k = 2$, índice silhouette = 0.1558). El análisis permitió identificar dos perfiles clínicamente diferenciados. El Clúster 0 agrupó 62,111 pacientes caracterizados por menor complejidad clínica y estancias hospitalarias cortas (aproximadamente 3 días), mientras que el Clúster 1 incluyó 39,655 pacientes con mayor complejidad clínica, mayor carga farmacológica (22 medicamentos en promedio) y estancias hospitalarias prolongadas (aproximadamente 6.6 días). Los resultados evidencian la utilidad de las técnicas de aprendizaje no supervisado para identificar patrones relevantes en poblaciones diabéticas y pueden contribuir a la toma de decisiones clínicas, la asignación de recursos y la estratificación de riesgo en entornos hospitalarios.

Keywords— Diabetes, exploratory data analysis, principal component analysis (PCA), K-Means clustering, healthcare data mining.

I. INTRODUCCIÓN

La diabetes mellitus representa una de las enfermedades crónicas con mayor impacto sobre los sistemas de salud a nivel global. Según la Organización Mundial de la Salud, más de 422 millones de personas padecen diabetes en el mundo, y la enfermedad es responsable de millones de muertes anuales. En el contexto hospitalario, los pacientes diabéticos presentan particularidades clínicas que incrementan la complejidad de su atención, por ejemplo, mayor número de comorbilidades, alta tasa de reingresos, uso intensivo de medicamentos y estancias prolongadas en hospitales. (OMS, s.f)

La diversidad de esta población dificulta la aplicación de protocolos de atención uniformes, lo que motiva la búsqueda de

métodos analíticos capaces de identificar subgrupos con características compartidas. El análisis de grandes volúmenes de datos clínicos mediante técnicas de aprendizaje automático no supervisado ofrece una ventaja para descubrir patrones y orientar la toma de decisiones clínicas y operativas.

El trabajo presente toma el [Diabetes 130-US Hospitals Dataset](#) como base de datos. La pregunta analítica central es: ¿qué perfiles de pacientes diabéticos hospitalizados pueden identificarse a partir de sus características demográficas, clínicas y uso de servicios de salud?

II. OBJETIVOS

A. Objetivo general

Caracterizar perfiles de pacientes diabéticos hospitalizados mediante un análisis exploratorio y clustering no supervisado, con el propósito de identificar patrones relevantes que puedan orientar estrategias de atención diferenciada.

B. Objetivos específicos

- Analizar la distribución de las variables demográficas y clínicas.
- Identificar relaciones entre variables de hospitalización, medicamentos y uso de servicios.
- Detectar y documentar valores atípicos.
- Aplicar reducción de dimensionalidad y agrupamiento.
- Interpretar los perfiles desde una perspectiva clínica y operativa.

III. METODOLOGÍA

A. Fuente y características del conjunto de datos

El conjunto de datos utilizado es el Diabetes 130-US Hospitals Dataset, disponible en el repositorio UCI Machine Learning Repository. Contiene 101.766 registros de encuentros hospitalarios de pacientes diabéticos atendidos en 130 hospitales de Estados Unidos entre 1999 y 2008, con 50 variables por registro. Las variables se agrupan en cuatro categorías:

- **Demográficas:** raza, género y grupo de edad.

- **Clínicas:** diagnóstico primario, secundario y terciario, niveles de glucosa sérica, resultado de HbA1c y 23 variables de medicamentos antidiabéticos.
- **Uso hospitalario:** días de estancia, número de procedimientos de laboratorio, procedimientos médicos, medicamentos prescritos y número de diagnósticos.
- **Historial de servicios:** visitas ambulatorias, urgencias, hospitalizaciones previas y estado de readmisión.

El dataset codifica los valores ausentes con el símbolo '?' que fue reemplazado por 'NaN' antes del análisis. Las variables 'weight' (96.8% ausente), 'max_glu_serum' (94.7% ausente) y 'A1Cresult' (83.3% ausente) presentaron tasas de omisión muy elevadas, por lo que fueron excluidas del análisis.

B. Análisis exploratorio

Se realizó un análisis univariado de las variables numéricas y categóricas. El análisis bivariado examinó relaciones entre tiempo de hospitalización y readmisión mediante boxplots, entre medicamentos y readmisión mediante gráficos de violín, y la distribución etaria de los pacientes. El análisis multivariado incluyó matrices de correlación ampliadas para ocho variables numéricas clave ('time_in_hospital', 'num_lab_procedures', 'num_procedures', 'num_medications', 'number_outpatient', 'number_emergency', 'number_inpatient', 'number_diagnoses') y un pairplot segmentado por tipo de admisión.

C. Detección de datos atípicos

Se aplicaron tres métodos complementarios para la detección de valores atípicos en ocho variables numéricas de interés clínico:

- Método IQR
- Z-score (umbral $|z| > 3$)
- Isolation Forest

Dado que el análisis busca identificar perfiles, los valores atípicos se conservan en el análisis exploratorio. El escalado con 'StandardScaler' mitiga su influencia sobre las distancias euclidianas en clustering. Los registros anómalos detectados por Isolation Forest se documentaron pero no se eliminaron, ya que pueden representar el perfil clínico más crítico.

D. Preprocesamiento: imputación y codificación de variables

Las variables 'weight' (96,8 %), 'max_glu_serum' (94,7 %) y 'A1Cresult' (83,3 %) fueron excluidas del análisis dado que su alta tasa de ausencias impediría cualquier imputación confiable y sesgaría los resultados. Para 'payer_code' y 'medical_specialty' se creó la categoría 'Desconocido' en lugar de eliminar las filas, preservando así el resto de la información clínica de esos registros. La variable 'race' fue imputada con la moda ('Caucasian') al presentar solo un 2,2 % de ausencias, porcentaje suficientemente bajo para que esta estrategia no distorsione la distribución original. Las filas con valores faltantes en 'diag_1', 'diag_2' y 'diag_3' fueron eliminadas por representar menos del 0,5 % del total, una pérdida despreciable.

La codificación de variables categóricas se definió en función de la naturaleza semántica de cada variable, distinguiendo entre aquellas que presentan un orden y aquellas que no. Para las

primeras se aplicó codificación ordinal y para las segundas se empleó codificación binaria.

La elección de codificación ordinal sobre alternativas como one-hot encoding se consideró dado que K-Means minimiza distancias euclidianas, asignar representaciones numéricas que respeten el orden real de las categorías permite que el algoritmo interprete correctamente la proximidad entre observaciones.

Bajo este criterio, se aplicó codificación ordinal a tres variables. La variable 'age', cuyos rangos etarios [0-10), [10-20), ..., [90-100) fueron mapeados a los valores enteros 0-9, dado que representan una progresión biológica continua y médicamente interpretable. La variable 'readmitted' fue codificada como NO=0, >30=1 y <30=2, reflejando una escala de urgencia clínica creciente: la ausencia de reingreso constituye el estado de menor gravedad, seguida del reingreso tardío y, finalmente, del reingreso temprano, que indica una evolución clínica desfavorable en el corto plazo.

La variable 'insulin' fue ordenada como No=0, Steady=1, Down=2 y Up=3, ya que esta secuencia representa una intensidad terapéutica creciente. Si bien tanto 'Down' como 'Up' implican ajustes activos, la dirección al alza refleja una necesidad de intensificación ante un control glucémico insuficiente, lo que es indicativo de una mayor inestabilidad metabólica y, por ende, de una mayor complejidad en el manejo farmacológico del paciente, a diferencia de la reducción de dosis asociada a 'Down'.

Finalmente, la variable 'gender' recibió codificación binaria (Male=0, Female=1) al tratarse de una variable dicotómica sin relación de orden entre sus categorías.

E. Reducción de la dimensionalidad y clustering

Con el fin de reducir la dimensionalidad del espacio de variables y eliminar la redundancia entre características correlacionadas, se aplicó PCA. El número de componentes retenidos se determinó mediante el criterio de varianza explicada acumulada, seleccionando el mínimo número de componentes necesarios para superar el umbral del 80 %, lo que resultó en 9 componentes principales. Esta decisión equilibra la reducción de ruido dimensional con la preservación de la mayor parte de la estructura informativa del conjunto de datos, condición necesaria para garantizar la estabilidad del algoritmo de agrupamiento posterior.

Sobre el espacio reducido de 9 componentes se ejecutó el algoritmo K-Means para valores de $k \in \{2, \dots, 8\}$, inicializando cada modelo con 10 ejecuciones aleatorias independientes para mitigar la sensibilidad del algoritmo a la inicialización de centroides. La selección del número óptimo de clústeres se realizó mediante dos criterios complementarios, el método del codo y el índice de silueta. Ante la ausencia de un quiebre pronunciado en la curva de inercia, la selección recayó sobre $k = 2$ por ser el valor que maximizó el índice de silueta (0,1558). Si bien este valor refleja una separación moderada entre clústeres, es consistente con la naturaleza continua de los datos clínicos y con los resultados reportados en estudios de agrupamiento sobre registros hospitalarios de pacientes con enfermedades crónicas.

F. Herramientas y librerías utilizadas

El trabajo se desarrolló empleando las librerías: NumPy, Pandas, Matplotlib, Seaborn, SciPy, Scikit-learn. En cuanto a las herramientas, se usó Google Colab como editor de código y Google Docs para la realización del artículo.

IV. RESULTADOS Y ANÁLISIS

A. Análisis univariado

Las distribuciones de las principales variables numéricas muestran patrones relevantes para comprender el comportamiento de los pacientes diabéticos hospitalizados.

La distribución del tiempo de hospitalización muestra una marcada asimetría positiva, la mayoría de los pacientes permanece entre 1 y 7 días, con un pico pronunciado en estancias cortas. Esto refleja que los casos más frecuentes corresponden a episodios agudos o de control rutinario, mientras que una minoría con complicaciones graves presenta estancias prolongadas (Fig 1).




Fig 1. Distribución del tiempo en el hospital de los pacientes

El número de procedimientos de laboratorio sigue una distribución más simétrica, centrada aproximadamente en 43 procedimientos por estancia. Esta distribución sugiere que existe un protocolo diagnóstico estándar para la mayoría de los pacientes, con menor variabilidad que otras variables de uso hospitalario (Fig 2).




Fig 2. Distribución del número de procedimientos de laboratorio por paciente.

El número de medicamentos exhibe alta variabilidad, con concentración en valores intermedios pero una cola derecha significativa que refleja la existencia de pacientes con regímenes farmacológicos muy complejos. Esta variable será uno de los principales diferenciadores entre los perfiles identificados mediante clustering (Fig 3).




Fig 3. Distribución de medicamentos prescritos por paciente.

La distribución por género muestra un relativo equilibrio, con una ligera mayoría de pacientes de sexo femenino (Fig 4). En cuanto a la raza (Fig 5), la muestra refleja la composición demográfica de los hospitales participantes, con predominio del grupo Caucásico, seguido por pacientes de raza Afroamericana. Esto debe tenerse en cuenta al generalizar los resultados.




Fig 4. Distribución de pacientes por género.




Fig 5. Distribución de pacientes por raza.

La mayoría de los pacientes no fue readmitida durante el periodo de seguimiento (categoría NO). Los reingresos tardíos (>30 días) superan a los tempranos (<30 días), lo que indica que las complicaciones que generan rehospitalización tienden a manifestarse de forma diferida (Fig 6).




Fig 6. Distribución de pacientes según tiempo de readmisión.

B. Análisis bivariado

El gráfico de violín (Fig. 7) muestra que la distribución del número de medicamentos es similar entre los tres grupos de readmisión, con medianas cercanas a los 15 medicamentos. Sin embargo, los pacientes readmitidos antes de 30 días presentan una distribución ligeramente más concentrada en valores intermedios y una densidad más pronunciada en el rango de 15 a 25 medicamentos, lo que sugiere que una carga farmacológica moderada-alta podría estar asociada con reingresos tempranos. La ausencia de diferencias marcadas entre grupos indica que el número de medicamentos, por sí solo, no es un predictor determinante del tipo de readmisión, sino que debe analizarse en conjunto con otras variables clínicas.




Fig 7. Número de medicamentos por tipo de readmisión.

El boxplot (Fig 8) revela que los pacientes no readmitidos presentan estancias hospitalarias medianas más cortas (aproximadamente 3 días) en comparación con los grupos readmitidos (mediana cercana a 4–5 días), independientemente del momento del reingreso. Los pacientes con readmisión temprana (<30 días) exhiben una distribución de estancias más compacta y con menor dispersión, lo cual podría indicar que estos episodios corresponden a complicaciones agudas de corta resolución que, no obstante, derivan en una evolución clínica desfavorable posterior. La presencia de valores atípicos en los tres grupos, con estancias de hasta 14 días, refleja la diversidad de la población diabética hospitalizada.




Fig 8. Tiempo en el hospital según readmisión.

C. Análisis multivariado

La matriz de correlación (Fig. 9) muestra que las relaciones lineales entre las variables numéricas clave son en general moderadas o bajas, lo que confirma la complejidad multidimensional del fenómeno clínico analizado. La correlación más alta se observa entre *'time_in_hospital'* y *'num_medications'* ($r = 0.47$), lo que es clínicamente coherente. Dado que estancias más prolongadas se asocian con un mayor número de medicamentos prescritos. Asimismo, *'num_medications'* y *'num_lab_procedures'* presentan una correlación moderada ($r = 0.39$), reflejando que los pacientes con mayor complejidad farmacológica requieren también más intervenciones.

Por otro lado, las variables de historial de servicios (*'number_outpatient'*, *'number_emergency'* y *'number_inpatient'*) muestran correlaciones muy bajas con las variables de uso intrahospitalario, lo que sugiere que el comportamiento previo del paciente en el sistema de salud no determina linealmente la intensidad de la atención durante la hospitalización actual.

Esta baja multicolinealidad general resulta favorable para la estabilidad del análisis de componentes principales aplicado en la siguiente etapa.




Fig 9. Matriz de correlación entre variables numéricas clave.

La matriz de correlación entre las tres principales variables de uso hospitalario revela relaciones lineales positivas moderadas (Fig 10), confirmando la naturaleza multifactorial de la atención clínica. Como se evidenció anteriormente, la asociación más significativa se presenta entre *'time_in_hospital'* y *'num_medications'* ($r = 0.46$), lo cual resulta clínicamente coherente dado que las estancias prolongadas suelen demandar esquemas farmacológicos más extensos. Por el contrario, la relación entre *'time_in_hospital'* y *'num_lab_procedures'* es más tenue ($r = 0.27$), sugiriendo que la duración de la hospitalización no condiciona de manera lineal el volumen de actividad diagnóstica. Finalmente, *'num_medications'* y *'num_lab_procedures'* exhiben la correlación más baja ($r = 0.23$), lo que indica que la intensidad terapéutica y diagnóstica responden a dimensiones clínicas parcialmente independientes. Esta baja multicolinealidad general es favorable para garantizar la estabilidad del análisis de componentes principales en las fases subsiguientes.




Fig 10. Matriz de correlación entre variables numéricas clave (acercamiento).

Complementariamente, el pairplot segmentado por tipo de admisión (Fig. 11) permite explorar las relaciones entre pares de variables de uso hospitalario según la vía de ingreso del paciente.

Se observa que los tres grupos (NO, >30 días y <30 días) presentan distribuciones ampliamente superpuestas en todos los pares de variables analizadas. Ninguna combinación de variables genera una separación visual clara entre los grupos de readmisión, lo que confirma que las variables de uso hospitalario consideradas de forma aislada no permiten discriminar linealmente el comportamiento de reingreso. Este resultado es consistente con el análisis bivariado previo y refuerza la necesidad de un enfoque multivariado y no supervisado para identificar patrones diferenciados en esta población.




Fig 11. Pairplot segmentado por tipo de readmisión

A partir de la figura 11, se puede resaltar también que:

- En *'number_inpatient'* sí se nota una tendencia leve: los puntos celestes (<30 días) aparecen ligeramente más dispersos hacia valores altos, sugiriendo que pacientes

con más hospitalizaciones previas tienen algo más de probabilidad de reingreso temprano.

- Las distribuciones diagonales muestran que 'num_lab_procedures' tiene la forma más simétrica de las cuatro, mientras time_in_hospital y 'number_inpatient' son las más asimétricas, consistente con lo reportado en el análisis univariado.

D. Detección de valores atípicos

Los boxplots generados mediante el método IQR permiten identificar el comportamiento distribucional de las ocho variables numéricas de interés clínico y la presencia de valores extremos en cada una. Las variables de historial de servicios ('number_inpatient', 'number_emergency' y 'number_outpatient') presentan la mayor concentración de valores atípicos en la cola superior, lo que refleja que una minoría de pacientes hace un uso recurrente e intensivo de los servicios de salud. En contraste, variables como 'time_in_hospital' y 'num_medications' muestran distribuciones más concentradas con valores atípicos moderados, consistentes con los patrones observados en el análisis univariado. Estos resultados confirman la asimetría positiva característica de las variables de utilización hospitalaria en poblaciones con enfermedades crónicas. (Fig 12)




Fig 12. Detección de outliers con método IQR.

La comparación entre los métodos IQR y Z-score (Fig. 13) revela diferencias sistemáticas en la sensibilidad de cada enfoque. El método IQR detecta consistentemente un mayor número de valores atípicos en todas las variables analizadas, dado que su criterio se basa en la dispersión intercuartílica y es más sensible a valores alejados de la mediana en distribuciones asimétricas. El Z-score, al asumir distribuciones aproximadamente normales y emplear un umbral de $|z| > 3$, resulta más conservador y detecta principalmente los casos más extremos. La diferencia más marcada entre ambos métodos se observa en 'number_outpatient' y 'number_emergency', variables con distribuciones fuertemente sesgadas y colas largas, donde el IQR identifica varios miles de registros adicionales que el Z-score no captura. Esta divergencia no implica que uno de los métodos sea incorrecto, sino que refleja la sensibilidad diferencial de cada criterio ante la forma de la distribución subyacente.




Fig 13. Comparación método IQR vs. Z-score por variable clave.

El análisis con Isolation Forest (Fig. 14), proyectado sobre las dos primeras componentes principales, permite identificar espacialmente los registros anómalos dentro de la estructura global del conjunto de datos. Los puntos clasificados como anómalos se ubican predominantemente en los extremos del eje PC1 y en los valores más elevados de PC2, regiones del espacio que corresponden a combinaciones inusuales de variables de uso hospitalario intensivo y carga farmacológica elevada. Dado que PC1 captura principalmente la varianza asociada a la complejidad clínica (con altas cargas de 'num_medications', 'time_in_hospital' y 'num_lab_procedures') los registros anómalos detectados representan con alta probabilidad el perfil de mayor gravedad dentro de la población diabética hospitalizada. En coherencia con la estrategia metodológica definida, estos registros fueron documentados pero conservados en el análisis, ya que su exclusión podría suprimir información clínicamente relevante sobre los casos más críticos. En total, Isolation Forest identificó 5,089 registros anómalos (5,0% de la muestra), frente a 96,677 registros normales (95%).




Fig 14. Anomalías en espacio PCA con Isolation forest.

E. Reducción de la dimensionalidad

La curva de varianza explicada acumulada (Fig. 15) muestra que la información del conjunto de datos se distribuye de forma relativamente uniforme entre los componentes, sin que ninguno de ellos concentre una proporción dominante de la varianza. Los dos primeros componentes explican conjuntamente el 30.5 % de la varianza total (PC1: 17.9 %, PC2: 12.6 %), mientras que se requieren 9 componentes para superar el umbral del 80 %. Este comportamiento es característico de conjuntos de datos clínicos con múltiples dimensiones moderadamente correlacionadas, donde la estructura informativa no colapsa fácilmente en pocas direcciones. La elección de 9 componentes principales garantiza la preservación de la mayor parte de la variabilidad original, al tiempo que reduce el ruido dimensional y la redundancia entre variables, condiciones necesarias para mejorar la estabilidad del

agrupamiento posterior.




Fig 15. Varianza explicada por los componentes principales.

El mapa de cargas por variable (Fig. 16) permite interpretar la estructura semántica de cada componente principal. PC1 concentra las cargas más altas en ‘num_medications’ (0.54), ‘time_in_hospital’ (0.49), ‘num_lab_procedures’ (0.36), ‘number_diagnoses’ (0.36) y ‘num_procedures’ (0.28), configurando un eje de complejidad clínica intrahospitalaria.

Los pacientes con valores positivos elevados en PC1 corresponden a casos con mayor carga asistencial durante la hospitalización. PC2, por su parte, recibe cargas destacadas de ‘number_inpatient’ (0.56) y ‘number_emergency’ (0.50), lo que sugiere que este componente captura principalmente el historial de uso previo de servicios de salud, diferenciando a los pacientes con mayor frecuencia de hospitalizaciones y atenciones de urgencia anteriores. PC3 está dominado por ‘age’ (0.72) y ‘gender’ (0.22), representando el perfil sociodemográfico del paciente.

Los componentes restantes capturan patrones de menor magnitud asociados a combinaciones de variables de uso ambulatorio, prescripción de insulina y readmisión, que en conjunto completan la estructura informativa retenida.




Fig 16. Carga por variable en los componentes principales.

La proyección de los pacientes sobre los dos primeros componentes principales (Fig. 17) muestra una nube de puntos continua y sin separaciones nítidas, con mayor densidad en torno al origen y una extensión asimétrica hacia valores positivos de PC1. La ausencia de agrupamientos visualmente discretos no invalida el análisis, sino que refleja que las diferencias entre perfiles de pacientes son de carácter gradual y multidimensional, lo que justifica la necesidad de incorporar los 9 componentes en lugar de proyectar sobre las dos primeras dimensiones para realizar el agrupamiento.




Fig 17. Proyección de pacientes en las componentes principales.

F. Clustering con K-Means

La curva de inercia del método del codo presenta un descenso continuo y gradual sin un quiebre pronunciado en ningún valor de k (Fig 18), comportamiento habitual en conjuntos de datos clínicos con fronteras naturalmente difusas entre subpoblaciones. Ante la ausencia de un punto de inflexión claro, la selección del número óptimo de clústeres se apoyó principalmente en el índice de silueta.

Este índice alcanza su valor máximo en k = 2 (0.1558), con una caída notable en k = 3 y fluctuaciones de menor magnitud para valores superiores, lo que indica que la bipartición del espacio es la que mejor captura la estructura latente del conjunto de datos bajo el criterio de compacidad y separación intragrupo. Aunque el valor obtenido refleja una separación moderada, es consistente con la naturaleza continua y multidimensional de los registros clínicos, donde los perfiles de pacientes no presentan fronteras abruptas sino gradientes clínicos.




Fig 18. Método del codo e índice de silueta.

La visualización de los dos clústeres sobre las dos primeras componentes principales muestra que la separación entre grupos ocurre principalmente a lo largo del eje PC1, asociado a la complejidad clínica intrahospitalaria. (Fig 19)

El Clúster 0 (Paciente diabético estable de baja complejidad) agrupa la mayoría de los pacientes en la región de valores negativos a moderadamente positivos de PC1, lo que corresponde a casos de menor carga asistencial. El Clúster 1 (Paciente diabético de alta complejidad y alta utilización), en cambio, concentra sus puntos hacia valores más elevados de PC1, representando pacientes con mayor uso de recursos durante la hospitalización.

Los centroides de ambos grupos reflejan esta separación horizontal, con el centroide del Clúster 1 desplazado claramente

hacia la derecha respecto al del Clúster 0. La superposición parcial visible en la proyección bidimensional es esperable dado que el agrupamiento se realizó sobre los 9 componentes principales, la proyección sobre solo dos dimensiones subestima la separación real existente en el espacio de mayor dimensionalidad.




Fig 19. Clústeres de pacientes en espacio PCA.

G. Caracterización de perfiles

La tabla de perfiles por clúster evidencia diferencias sistemáticas y clínicamente interpretables entre ambos grupos en todas las variables analizadas (Fig 20). El Clúster 0, con 62,111 pacientes (61% de la muestra), corresponde a un perfil de baja complejidad:

- Estancias cortas (≈ 3 días).
- Menor carga farmacológica (≈ 12 medicamentos).
- Menos procedimientos de laboratorio (≈ 36).
- Escaso historial de hospitalizaciones previas (0.39 en promedio).

El Clúster 1, con 39,655 pacientes, representa un perfil de alta complejidad clínica:

- Las estancias se duplican (≈ 6.6 días).
- Los medicamentos prescritos casi se duplican (≈ 22).
- Los procedimientos de laboratorio aumentan en un 49% (≈ 54).
- El número de diagnósticos concurrentes es mayor (8.39 vs. 6.81).

Destaca también que los pacientes del Clúster 1 presentan un historial de hospitalizaciones previas considerablemente más elevado (1.02 vs. 0.39), lo que sugiere que se trata de una población con mayor cronicidad y recurrencia en el uso de servicios hospitalarios. La readmisión media, codificada ordinalmente, es también superior en este grupo (0.75 vs. 0.46), indicando una evolución clínica más desfavorable.




Fig 20. Caracterización de perfiles de pacientes por clúster.

El gráfico de radar (Fig 21) permite comparar simultáneamente los seis indicadores clínicos normalizados entre ambos perfiles. El polígono del Clúster 1 (azul oscuro) es sistemáticamente más amplio que el del Clúster 0 (teal) en cinco de las seis dimensiones, lo que confirma visualmente su mayor complejidad clínica.

La diferencia más pronunciada se observa en hospitalizaciones previas, donde el Clúster 1 presenta un vértice notablemente más extendido, revelando que estos pacientes tienen un historial de uso recurrente del sistema hospitalario muy superior al del Clúster 0. Le siguen en magnitud de diferencia los días de hospitalización y el número de medicamentos, variables que en conjunto configuran el eje de carga asistencial intrahospitalaria.

Las diferencias en procedimientos de laboratorio y número de diagnósticos son moderadas pero consistentes, reforzando el patrón de mayor intensidad diagnóstica y terapéutica en el Clúster 1.

La variable edad es la única donde ambos polígonos convergen casi al mismo valor, lo que indica que la segmentación obtenida no responde a un gradiente etario sino fundamentalmente a la intensidad del uso de recursos sanitarios y al historial clínico previo del paciente. Esto tiene una implicación clínica relevante, dos pacientes de edad similar pueden pertenecer a perfiles de riesgo radicalmente distintos dependiendo de su trayectoria hospitalaria previa y su carga farmacológica actual.




Fig 21. Perfiles clínicos por clúster.

La distribución de readmisión por clúster revela diferencias clínicamente relevantes en la evolución posterior a la hospitalización (Fig 22).

En el Clúster 0, aproximadamente el 61% de los pacientes no fue readmitido, el 31% reingresó después de 30 días y solo el 8% presentó reingreso temprano (< 30 días), patrón consistente con episodios de atención aguda o rutinaria de resolución favorable.

En el Clúster 1, en cambio, la distribución es sustancialmente distinta, indicando que la proporción de pacientes no readmitidos cae al 42%, mientras que los reingresos tardíos aumentan al 41% y los tempranos alcanzan el 17%.

Este incremento en la tasa de readmisión temprana en el Clúster 1 es clínicamente significativo, ya que los reingresos antes de 30 días son el indicador más sensible de complicaciones derivadas de una evolución clínica desfavorable y están asociados en la literatura con mayores costos hospitalarios y peores desenlaces en salud. La figura valida externamente la segmentación obtenida, los perfiles identificados no solo difieren en variables de uso intrahospitalario, sino también en su trayectoria clínica posterior, lo cual refuerza la utilidad del clustering como herramienta de estratificación de riesgo.




Fig 22. Distribución de readmisión por clúster.

V. CONCLUSIONES

El análisis exploratorio y de agrupamiento no supervisado aplicado sobre el Diabetes 130-US Hospitals Dataset permitió identificar dos perfiles clínicamente diferenciados de pacientes diabéticos hospitalizados, respondiendo así la pregunta analítica central del estudio.

El Clúster 0 representa el perfil de paciente diabético de baja complejidad clínica. Agrupa el 61% de la muestra (62,111 pacientes) y se caracteriza por estancias hospitalarias cortas (≈ 3 días), un régimen farmacológico moderado (≈ 12 medicamentos), menor número de procedimientos diagnósticos y escaso historial de hospitalizaciones previas. La mayoría de estos pacientes no fue readmitida ($\approx 61\%$), lo que indica episodios hospitalarios de resolución favorable, probablemente asociados a controles de rutina o complicaciones agudas de baja gravedad.

El Clúster 1 configura el perfil de paciente diabético de alta complejidad clínica y mayor riesgo. Comprende el 39% de la muestra (39,655 pacientes) y se distingue por estancias prolongadas (≈ 6.6 días), alta carga farmacológica (≈ 22 medicamentos), mayor número de procedimientos de laboratorio (≈ 54), más diagnósticos concurrentes (≈ 8.4) y un historial significativo de hospitalizaciones y urgencias previas. Notablemente, la variable edad presenta valores casi idénticos entre ambos clústeres, lo que indica que la diferenciación entre

perfiles no obedece a un gradiente etario sino a la intensidad del uso de recursos sanitarios y a la trayectoria clínica previa del paciente. Además, presenta tasas de readmisión considerablemente más altas, incluyendo una proporción de reingresos tempranos (< 30 días) del 17%, frente al 8% del Clúster 0. Este perfil sugiere una población con diabetes de larga evolución, con comorbilidades activas y una dinámica de uso intensivo y recurrente de los servicios de salud.

Desde una perspectiva metodológica, la aplicación de PCA con 9 componentes, que explican más del 80% de la varianza, fue determinante para estabilizar el agrupamiento en un espacio de datos clínicos moderadamente correlacionados. El índice de silueta de 0.1558 para $k = 2$, aunque modesto, es coherente con la naturaleza continua de los registros hospitalarios. Parikh et al. (2023), aplicando clustering sobre datos clínicos de pacientes diabéticos, reportaron índices de silueta promedio de 0.32 y 0.36, señalando que la heterogeneidad clínica intrínseca de estas poblaciones limita la separación entre grupos. En conjuntos de datos hospitalarios de mayor escala y diversidad, como el utilizado en el presente estudio, un solapamiento aún mayor entre perfiles es esperable dado que los pacientes no presentan fronteras clínicas abruptas sino gradientes de severidad.

Finalmente, los resultados obtenidos tienen implicaciones directas para la toma de decisiones clínicas, explicando que la identificación temprana de pacientes con características propias del Clúster 1 podría orientar estrategias de atención diferenciada, asignación prioritaria de recursos, seguimiento post-alta más intensivo y diseño de intervenciones preventivas para reducir los reingresos tempranos. Como limitación principal, el índice de silueta moderado y la ausencia de información en variables clave como peso y niveles de HbA1c sugieren que la granularidad de la segmentación podría mejorarse con datos clínicos más completos o con la incorporación de técnicas de clustering más robustas ante distribuciones asimétricas, como clustering jerárquico o modelos de mezclas gaussianas.

VI. REFERENCIAS

1. Bernarda, M. [mariabda2]. (2026). *intro_data_2026* [Repositorio de GitHub]. GitHub. https://github.com/mariabda2/intro_data_2026
2. Mayo Clinic. (s.f.). *Diabetes: síntomas y causas*. <https://www.mayoclinic.org/es/diseases-conditions/diabetes/symptoms-causes/syc-20371444>
3. Organización Mundial de la Salud. (s.f.). *Diabetes*. <https://www.who.int/es/news-room/fact-sheets/detail/diabetes>
4. Parikh, H. M., Remedios, C. L., Hampe, C. S., Balasubramanyam, A., Fisher-Hoch, S. P., Choi, Y. J., Patel, S., McCormick, J. B., Redondo, M. J., & Krischer, J. P. (2023). Data mining framework for discovering and clustering phenotypes of atypical diabetes. *The Journal of Clinical Endocrinology & Metabolism*, 108(4), 834–846. <https://doi.org/10.1210/clinem.dgac632>
5. Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). *Diabetes 130-US hospitals for years 1999–2008* [Conjunto de datos]. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008>